



جامعة دمشق
كلية الهندسة المعلوماتية
السنة الرابعة
الاختصاص: ذكاء صناعي

شبكات عصبونية (Heartbeat Categorization)

إعداد:

ياسين عبد المهدي

محمد كاتبة

يامن التكريتي

محمود كوكة

مقدمة:

_الداتا سيت المستخدمة هي مجموعة من البيانات المستخدمة في التدريب والتحقق من الشبكة MIT-BIH Arrhythmia العصبونية العميقة. هذه البيانات مأخوذة من مجموعة بيانات وتحتوي على عينات القلب المسجلة من نظام الإشارة الكهربائية في نسبة 187 مرة في الثانية. يتم وضع كل عينة في صف ويتم تصنيفها إلى أحد الخمسة فئات الضربات القلبية المختلفة.

_لتدريب وتقييم الشبكتين قامت باستخدام مجموعة داتا ECG التدريبية والاختبارية من مجموعة MIT-BIH Arrhythmia. تتكون المجموعة من عينات ECG التي تعرف تصنيفها. وتتكون المجموعة التدريبية من 87537 عينة وتتكون المجموعة الاختبارية من 21892 عينة. وقد تم تحليل دقة التصنيف للعينات التي تم تصنيفها كعينات نبض نمطي وعينات نبض أخرى.

_تم استخدام مجموعتين من الداتا سيت، وهما مجموعة "mitbih_train" لتدريب الشبكة ومجموعة "mitbih_test" لاختبارها.

_بنية الشبكة العصبونية العميقة المستخدمة في هذا المشروع هي مجموعة من الطبقات المتعددة التي تتكون من العديد من الخلايا العصبية. كل طبقة في الشبكة يتم تدريبها على التعلم والتنبؤ بالاستجابة المناسبة للبيانات المدخلة لها. في هذا المشروع، يتم استخدام تقنية الخسارة "loss" لتحديد كمية الخطأ الذي يحدث في التنبؤ التي يقوم بها الشبكة، ويتم استخدام هذه التقنية لتحسين الشبكة وتحليلها.

يتم استخدام:

1. حزمة "numpy" للعمليات الرياضية
2. حزمة "pandas" للتعامل مع الداتا سيت
3. حزمة "matplotlib" للرسم البياني
4. حزمة "seaborn" لتحليل الداتا

_تتم قراءة الداتا سبت "mitbih_train" و "mitbih_test" باستخدام دالة "read_csv" من حزمة "pandas" وتخزينها في متغيرات "train data" و "test data" على التوالي.

_بعد تدريب وتحليل الشبكة العصبونية العميقة، يمكن استخدام هذه الشبكة للتنبؤ بفئة القلب المحتملة للرسوم البيانية المدخلة للشبكة. يمكن استخدام هذه الشبكة في العديد من التطبيقات الطبية للتنبؤ بحالة القلب للمرضى والتحليل العميق للرسوم البيانية القلبية.

هناك العديد من العوامل التي يمكن أن تؤثر على اختيار الداتا سبت وبنية الشبكة العصبونية العميقة المستخدمة في المشروع. يجب التأكد من أن الداتا سبت المستخدمة هي مناسبة للمشروع وتحتوي على معلومات كافية ودقيقة لتدريب وتحليل الشبكة. يجب أيضاً التأكد من أن الشبكة العصبونية العميقة المستخدمة هي المناسبة للمشروع وتتيح نتائج مرضية في التنبؤ.

_عند اختيار الداتا سبت وبنية الشبكة العصبونية العميقة المناسبة للمشروع، يجب التأكد من أن الداتا سبت المستخدمة هي كافية في الحجم والجودة لتدريب الشبكة. يجب أيضاً التأكد من أن الداتا سبت متوازنة ما بين الفئات المختلفة ولا توجد تحيز في الداتا سبت إلى أي فئة معينة.

_عند اختيار عدد الطبقات المستخدمة في الشبكة العصبونية العميقة، يجب العلم أن العدد الأكبر للطبقات قد يؤدي إلى زيادة في دقة التنبؤات التي يقوم بها الشبكة. ولكن هذا قد يؤدي أيضاً إلى زيادة في عدد المعالجات اللازمة لتدريب الشبكة وقد يؤدي أيضاً إلى زيادة في وقت التدريب. لذلك، يجب التوازن بين عدد الطبقات ودقة التنبؤات المطلوبة.

_عند اختيار عدد الطبقات، يجب العلم أنه يمكن أن يكون العدد المثالي للطبقات مختلفاً من مشروع إلى مشروع وقد يتطلب التجربة والتحليل للعثور على العدد المناسب للطبقات في كل مشروع.

_يجب العلم أن الشبكات العصبية العميقة هي وسيلة قوية وفعالة للتنبؤات والتحليل العميق للداتا، ولكن يجب العلم أنه يتطلب وقتاً ومعالجة كبيرة لتدريب الشبكة وإيجاد النتائج المرضية.

لذلك، يجب التوازن بين المصلحة والعمل اللازم للحصول على نتائج مرضية من استخدام الشبكات العصبية العميقة.

_هناك العديد من العوامل التي يمكن أن تؤثر على نتائج الشبكة العصبونية العميقة وعلى دقة التنبؤات التي يقوم بها الشبكة.

ومن بين هذه العوامل:

1. **الداتا سيت المستخدمة:** يجب التأكد من أن الداتا سيت المستخدمة هي كافية في الحجم والجودة لتدريب الشبكة وأنها متوازنة ما بين الفئات المختلفة لتجنب التحيز.

2. **بنية الشبكة:** يجب التأكد من أن بنية الشبكة المستخدمة هي المناسبة للمشروع وتتيح نتائج مرضية في التنبؤ. يجب أيضاً العلم أن عدد الطبقات المستخدمة قد يؤثر على نتائج الشبكة.

3. **معامل التدريب (training loss):** هو قيمة معامل الخطأ (error metric) التي يتم استخدامها لتقييم الأداء العام للشبكة العصبونية على مجموعة البيانات التدريبية. عند التدريب على الشبكة العصبونية، يتم محاولة تحسين معامل التدريب من خلال التعديل على بنية الشبكة العصبونية و/أو معامل الخسارة (loss function).
_يجب العلم أن معامل التدريب قد يؤثر على نتائج الشبكة وعلى دقة التنبؤات. يجب التجربة والتحليل للعثور على المعامل المناسب للتدريب للحصول على نتائج مرضية.

4. **العمليات الرياضية المستخدمة:** يجب العلم أن العمليات الرياضية المستخدمة في الشبكة قد تؤثر على نتائج الشبكة وعلى دقة التنبؤات. يجب التجربة والتحليل للعثور على العمليات الرياضية المناسبة للحصول على نتائج مرضية.

5. **معامل الدفع (validation loss):** هو قيمة معامل الخطأ التي يتم استخدامها لتقييم الأداء العام للشبكة العصبونية على مجموعة البيانات التحقيقية (validation)

(dataset). يستخدم معامل الدفع للتحقق من أن الشبكة العصبونية لا تعاني من (overfitting) أو (underfitting)، وهي مشكلتين قد تؤدي إلى أداء ضعيف في البيانات التجريبية الأخرى. يجب العلم أن معامل الدفع قد يؤثر على نتائج الشبكة وعلى دقة التنبؤات. يجب التجربة والتحليل للعثور على معامل الدفع المناسب للحصول على نتائج مرضية.

6. **معامل الانحدار (test loss):** هو قيمة معامل الخطأ التي يتم استخدامها لتقييم الأداء العام للشبكة العصبونية على مجموعة البيانات الاختبارية (test dataset). يستخدم معامل الانحدار للتحقق من أن الشبكة العصبونية قد تعلمت كيفية معالجة البيانات الجديدة بشكل جيد يجب العلم أن معامل الانحدار قد يؤثر على نتائج الشبكة وعلى دقة التنبؤات. يجب التجربة والتحليل للعثور على معامل الانحدار المناسب للحصول على نتائج مرضية.

_عند العمل مع الشبكات العصبية العميقة، يجب العلم أن هناك العديد من العوامل التي يمكن أن تؤثر على نتائج الشبكة وعلى دقة التنبؤات. ولذلك، يجب العمل بعناية والتجربة والتحليل للعثور على العوامل المناسبة والإعدادات المناسبة للحصول على نتائج مرضية من استخدام الشبكات العصبية العميقة. يجب أيضاً العلم أن يمكن أن يتطلب وقتاً ومعالجة كبيرة لتدريب الشبكة وإيجاد النتائج المرضية، لذلك يجب التوازن بين المصلحة والعمل اللازم للحصول على نتائج مرضية من استخدام الشبكات العصبية العميقة.

الأسلوب العملي:

بنية الشبكة العصبونية الاولى:

_بنية الشبكة العصبونية العميقة المستخدمة هي مجموعة من الطبقات المتعددة التي تتكون من العديد من الخلايا العصبية. كل طبقة في الشبكة يتم تدريبها على التعلم والتنبؤ بالاستجابة المناسبة للبيانات المدخلة لها. في هذا المشروع، يتم استخدام تقنية "loss" لتحديد كمية الخطأ الذي يحدث في التنبؤ التي يقوم بها الشبكة، ويتم استخدام هذه التقنية لتحسين الشبكة وتحليلها.

تم تحويل الداتا التدريبية والاختبارية إلى الشكل المناسب للتدريب والاختبار على الشبكة العصبونية العميقة ويتم تدريب الشبكة على الداتا التدريبية وتحقق من دقة التدريب. ثم يتم استخدام الشبكة العصبونية العميقة المدربة للتنبؤ على الداتا الاختبارية ويتم التحقق من دقة التنبؤات مع النتائج المرجعية الخاصة بالداتا الاختبارية. ويتم عرض النتائج الخاصة بدقة التدريب والتنبؤات مع استخدام الرسم البياني.

وبالنسبة للشبكة العصبونية العميقة المستخدمة في هذا الكود، يتم استخدام أربع طبقات في الشبكة، وهي:

الطبقة الأولى: تتكون من 128 مجموعة من (neurons).

الطبقة الثانية: تتكون من 64 مجموعة من (neurons).

الطبقة الثالثة: تتكون من 32 مجموعة من (neurons).

الطبقة الرابعة: تتكون من 5 مجموعة من (neurons)، وهي الطبقة النهائية.

يتم اختيار هذا العدد من الطبقات وعدد ال neurons في كل طبقة لتلبية الحاجة إلى تدريب الشبكة العصبونية العميقة على الداتا التدريبية بدقة عالية. ويمكن أن يتم اختبار مدى فعالية هذا العدد من الطبقات وعدد الخلايا العصبونية المدمجة في كل طبقة من خلال التحقق من دقة التدريب ودقة التنبؤات. ويمكن أن يتم تغيير هذا العدد لتحسين الدقة إذا لزم الأمر.

ويتم استخدام الدالة الخاصة بالخسارة "**loss function**" التي تعرف أيضًا باسم "**cost function**" لتقييم كمية الخسارة التي تحدث في الشبكة العصبونية العميقة أثناء التدريب. ويتم استخدام دالة الخسارة "**categorical crossentropy**" في هذا الكود للتعامل مع التصنيف المتعدد المستويات. وهي دالة الخسارة الشائعة المستخدمة للتعامل مع التصنيف المتعدد المستويات وتساعد في تقليل الخسارة التي تحدث في الشبكة العصبونية العميقة أثناء التدريب.

ذلك عملية تحويل الداتا التدريبية والاختبارية إلى الشكل المناسب للتدريب والاختبار على الشبكة العصبونية العميقة. ويتم استخدام الدالة "**to categorical**" من مكتبة keras

لتحويل العمود إلى قائمة من القيم الصفرية والواحدة التي تمثل كل فئة فردية في الداتا. ويتم استخدام هذه القائمة الجديدة مع الداتا الأخرى لتعبئة العناصر التدريبية والاختبارية المراد استخدامها في الشبكة العصبونية العميقة.

_بعد ذلك، يتم تدريب الشبكة العصبونية العميقة على الداتا التدريبية باستخدام الدالة **"fit"** ويتم التحقق من دقة التدريب مع الداتا الاختبارية باستخدام الدالة **"evaluate"**. ويتم عرض النتائج الخاصة بدقة التدريب والتنبؤ في الشبكة العصبونية العميقة.

_تتبع الكود عملية توقع الشبكة العصبونية العميقة باستخدام الدالة **"predict"** وتخزين النتائج في متغير **"prediction"**. وبعد ذلك، يتم عرض مجموعة من النتائج الخاصة بالتنبؤات للمقارنة مع الداتا الحقيقية.

_ويتم استخدام بعض الدوال الرسومية من مكتبة **"seaborn"** لعرض مجموعة من الرسوم البيانية التي تساعد في التوضيح والفهم الأساسي للداتا التدريبية والاختبارية. ويتم استخدام الدالة **"resample"** من مكتبة **"sklearn"** لتعديل الداتا التدريبية بحيث يكون هناك نفس العدد لكل فئة فردية.

_يتم استخدام الدالة **"plot_confusion_matrix"** لعرض الخلية العينية التي توضح الدقة التي حصلت عليها الشبكة العصبونية العميقة في التنبؤات. وتساعد الخلية العينية في التعرف على الدقة العامة للشبكة العصبونية العميقة وكذلك توضح أي فئة فردية قد تكون هي السبب في تدهور الدقة في التنبؤات.

_في النهاية، يتم استخدام الدالة **"classification_report"** من مكتبة **"sklearn"** لعرض ملخص للدقة والدقة العامة للشبكة العصبونية العميقة في التنبؤات.

بنية الشبكة العصبونية الثانية:

تم بناء الشبكة العصبونية باستخدام Sequential class من tensorflow.keras.models والشبكة العصبونية تتألف من ثلاث طبقات:

1. طبقة الدخل تتألف من 187 وحدة و relu activation وهذه الطبقة تستقبل بيانات الدخل والتي تتألف من 187 features.
 2. Hidden layer تتألف من 100 وحدة و تابع relu activation تستخدم هذه الطبقة لمعرفة تمثيلات أكثر تعقيدا لبيانات الإدخال.
 3. طبقة الخرج والتي تتألف من 5 وحدات و softmax activation function وهذه الطبقة تنتج الخرج النهائي ل model وهو توزيع احتمالي على 5 تسميات فئة ممكنة.
- ثم يتم عمل compile ل model باستخدام طريقة Adam. وهي خوارزمية لضبط أوزان ال model لتقليل loss function، بالإضافة إلى categorical_crossentropy، وهو خيار شائع لمهام التصنيف، ومقياس الدقة، والذي يستخدم لتقييم أداء model.
- ثم يتم تدريب النموذج باستخدام fit، والتي تأخذ بيانات التدريب trainX والتسميات المقابلة trainY كدخل. يتم تقييم ال model أيضا على validation set، testX و testY، أثناء التدريب. تحدد batch size عدد العينات المراد استخدامها في كل تكرار (أي عدد العينات المراد معالجتها قبل تحديث أوزان ال model). تحدد epochs عدد المرات التي يمر فيها model ببيانات التدريب. تتحكم verbose في كمية المعلومات المعروضة أثناء التدريب.
- بعد التدريب، يتم تقييم ال model على مجموعة الاختبار باستخدام evaluate method، والتي ترجع categorical_crossentropy و accuracy على بيانات الاختبار.

نتائج التحليل والمقارنة:

(1) النتائج والتقييم لكلا الشبكتين:

بعد التحليل والنظر في نتائج الشبكتين وجدنا أن:

<u>من حيث:</u>	الشبكتة الأولى (بنية الشبكتة CNN)	الشبكتة الثانية (بنية الشبكتة MLP)
Accuracy (1)	• أعلى	• أقل
Loss (2) Function	• أقل • أفضل من الشبكتة الثانية (يقل بمعدل أسرع من الشبكتة الثانية)	• أعلى • أسوء من الشبكتة الأولى (يزداد بمعدل أسرع من الشبكتة الأولى)
(3) سرعة تنفيذ كل epoch	• ابطأ • يحتاج الى حوالي 70 ثانية لتنفيذ كل epoch	• أسرع • يحتاج الى حوالي ثانيتين لتنفيذ كل epoch

من ناحية الAccuracy :

ظهر لدينا Accuracy اعلى في الشبكتة الأولى من الثانية وذلك لان الشبكتة التي يتم تدريبها مع التكامل (CNNs) هي شبكات عصبية تعتمد على تصفية وتجميع المعلومات من الصور وعلى التكامل العامل للصورة كلها في المراحل المبكرة من التدريب. هذا يعني أنها تستخدم الخلايا الخاصة بتحليل المعلومات الموجودة في مساحة الصورة المعينة وتجمع هذه المعلومات في مراحل أخرى من التدريب.

_على العكس، شبكات العصب الدماغي التي يتم تدريبها بدون التكامل (MLPs) هي شبكات عصبية تعتمد على استخدام معلمات متجانسة لتحليل المعلومات وتجميعها. وهذا يعني أنها لا تستخدم التكامل العامل الذي يمكن أن يكون مفيداً في تحليل المعلومات الموجودة في مساحة الصورة المعينة.

_ومشروعنا هذا يعتمد على تصنيف نبضات القلب لذلك فان تصفية المعلومات وتجميعها في المراحل المبكرة سيعطي نتائج اعلى وهو ما تعتمد عليه الشبكة الاولى على خلاف الشبكة الثانية التي لا تستخدم التكامل وهو عامل مفيد في تحليل ضربات القلب الخاصة بمشروعنا.

_لذلك، فإن شبكات CNN قد تكون أكثر دقة من شبكات MLP في تعليم الآلة في العديد من الحالات، وذلك لأنها تعتمد على التكامل العامل لتحليل المعلومات الموجودة في مساحة الصورة المعينة، وهذا يساعد في تحليل العلاقات والتوافقات الموجودة بين العناصر المختلفة.

من ناحية loss function :

_تُسجّل إشارات مخطط كهربية القلب عادةً على أنها بيانات سلاسل زمنية، بدلاً من صور. لذلك، لن تحتوي مجموعة بيانات تصنيف ECG Heartbeat على صور، بل مجموعة من المصفوفات D1 التي تمثل إشارات ECG.

ومع ذلك، من الممكن تحويل إشارة ECG إلى تمثيل يشبه الصورة لأغراض تصور الإشارة أو إدخالها في CNN. تتمثل إحدى طرق القيام بذلك في رسم إشارة تخطيط القلب بمرور الوقت واستخدام المخطط الناتج كصورة. يمكنك بعد ذلك استخدام نفس الأساليب المستخدمة في مهام تصنيف الصور لتصنيف إشارات مخطط كهربية القلب باستخدام شبكة CNN.

_شبكات CNN مخصصة لمعالجة الصور وتستخدم مصفوفات التعديلات لتعريف العلاقات بين العناصر المجاورة في الصورة. هذا يعني أنها تمتلك قدرة عالية في التعلم من البيانات المرئية وفي التنبؤ بالنتائج بشكل أفضل.

_شبكات MLP هي شبكات فردية ولا تمتلك مصفوفات التعديلات الخاصة بشبكات CNN. وهذا يعني أنها لا تعرف العلاقات المحيطة بالبيانات المدخلة ولذلك قد تكون معقدة أكثر في التعلم من البيانات والتنبؤ بالنتائج بشكل أفضل.

_ولذلك كانت الشبكة الاولى أفضل من الثانية من ناحية loss function


من ناحية سرعة التنفيذ:

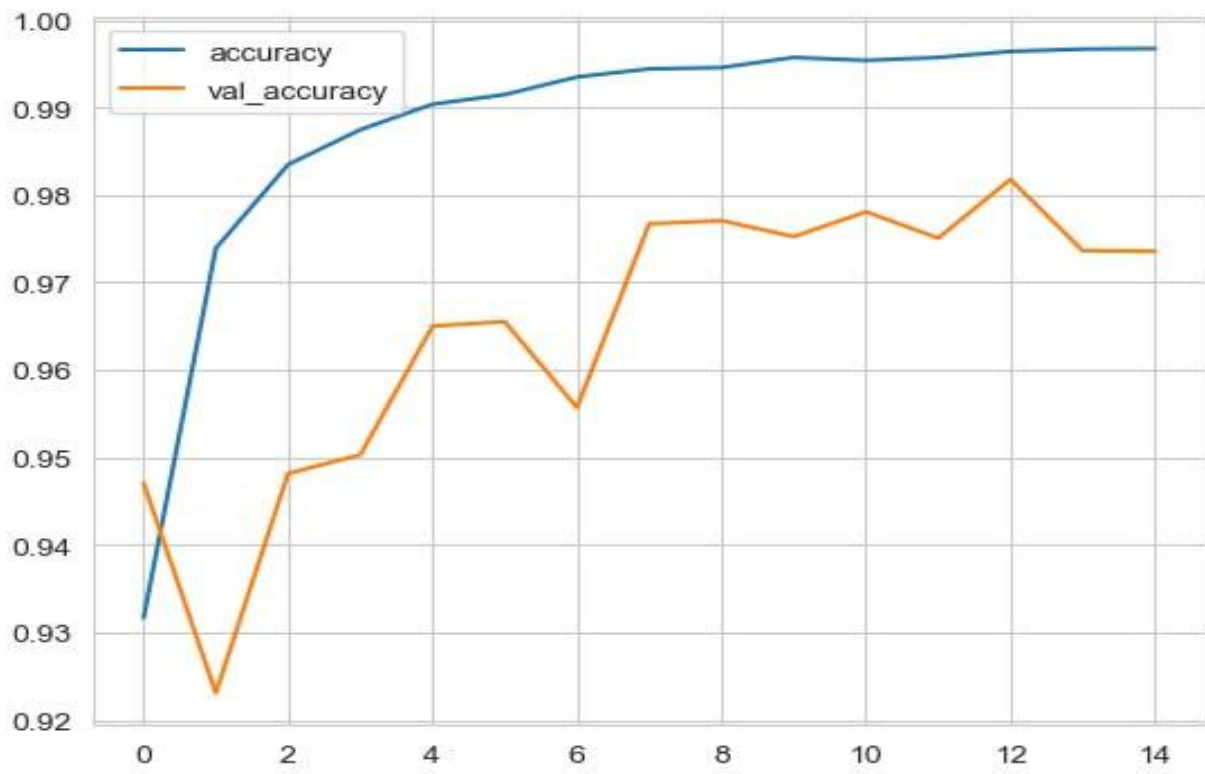
_تعتبر الشبكات العصبية الخاصة (MLPs) أسرع في التدريب من الشبكات العصبية الخاصة المتعددة الطبقات (CNNs) في العديد من الحالات. وهذا لأن MLPs عادة ما تكون أقل حجما وأقل عددا من الخطوط العصبية في مقارنة مع CNNs التي يمكن أن تكون أكبر حجما وأكثر عددا من الخطوط العصبية. وبالتالي يستغرق تدريب MLPs أقل وقتا في العديد من الحالات.

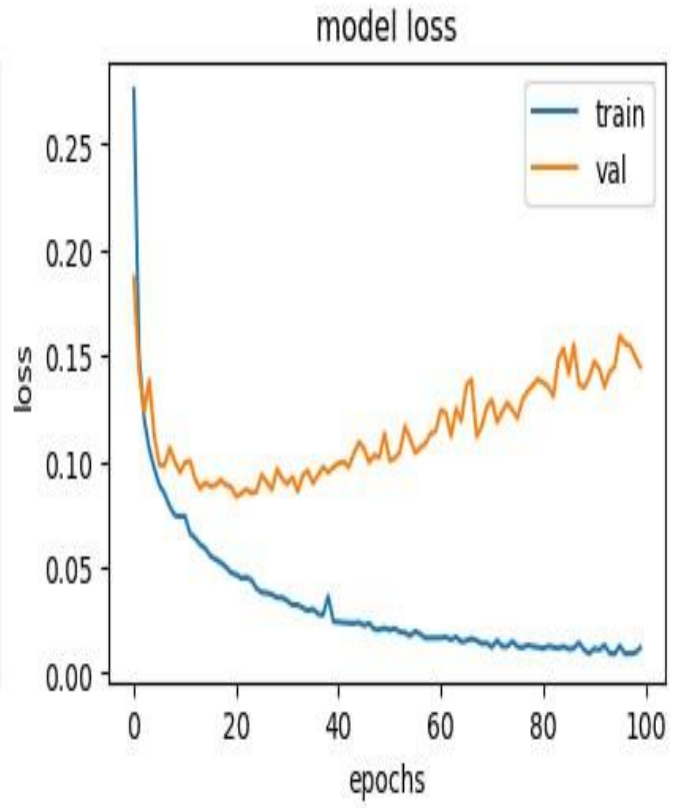
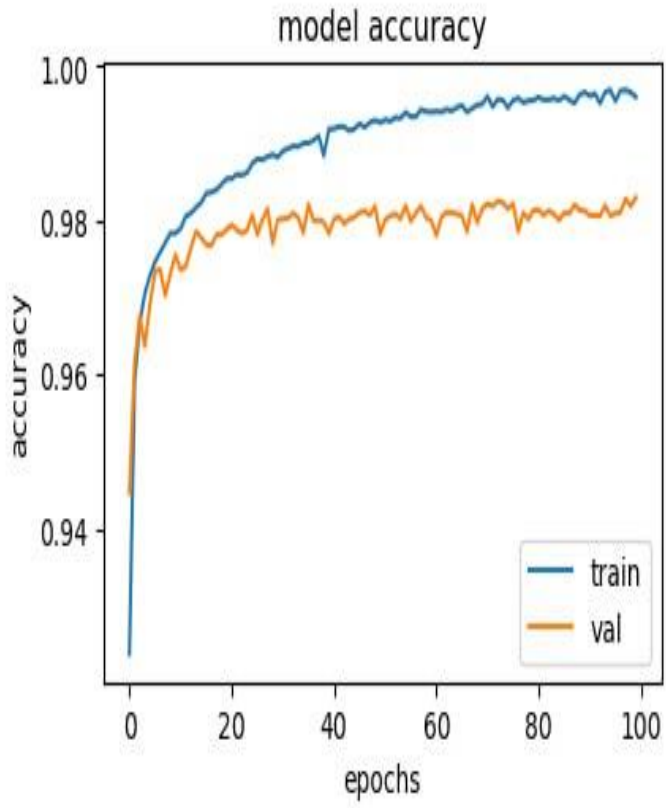
_مع ذلك، يجب ملاحظة أن هناك العديد من العوامل التي يمكن أن تؤثر على سرعة التدريب العامة للشبكة العصبية الخاصة، وبالتالي يمكن أن تكون سرعة التدريب في العديد من الحالات في MLPs مساوية أو أقل من CNNs. مثلا، قد يعتمد سرعة التدريب على العديد من العوامل مثل نوع المعلم المستخدم وتكوين الشبكة وترتيب البيانات وغيرها.

تقييم أداء الشبكتين وسلوكها باستخدام المخططات learning curve, generalization curve:

الشبكة الأولى:







تقسيم العمل:

تم تطبيق الشبكة الاولى باستخدام ال CNN من قبل ياسين عبد المهدي ومحمود كوكة وتم ايضاً كتابة جزء من التقرير الخاص بهذه الشبكة.

وتم تطبيق الشبكة الثانية وتحقيقها من قبل يامن التكريتي ومحمد كاتبة وايضاً كتابة الجزء من التقرير الخاص بهذه الشبكة.

تم عمل مقارنة وتقييم اداء الشبكتين من قبل جميع الطلاب.

المراجع:

<https://www.kaggle.com/datasets/shayanfazeli/heartbeat>

[/https://www.coursera.org](https://www.coursera.org)